

フィッティング適合度（Goodness of Fit）指標の整理

概要

本プロジェクトでは、ガウシアン関数によるフィッティングの適合度を評価するために、複数の統計指標を使用しています。これらの指標は、フィッティングモデルが観測データをどれだけ適切に説明しているかを定量的に評価するために用いられます。

使用されている指標の分類

1. 基本指標（全条件で使用）

1.1 Reduced χ^2 （正規化カイ二乗値）

定義:

$$\text{Reduced } \chi^2 = \chi^2 / (n - p)$$

- χ^2 : カイ二乗統計量（計算方法は条件によって異なる）
- n : データ点数
- p : パラメータ数（4: A, μ , σ , B）

計算式（条件によって異なる）:

cold/warm条件 (`Gaussian_fitting_integrate_cold.py`,
`Gaussian_fitting_integrate_warm.py`):

$$\chi^2 = \sum (y_{\text{obs}} - y_{\text{pred}})^2$$

- y_{obs} : 観測された成功率（比率データ）
- y_{pred} : フィッティングモデルによる予測確率
- 単純な残差平方和ベースの計算

spatial_cold条件 (`Gaussian_fitting_integrate_spatial_cold.py`):

$$\chi^2 = \sum [(k - n \cdot \hat{p})^2 / (n \cdot \hat{p} \cdot (1 - \hat{p}))]$$

- k : 各SOAでの成功数（同時性と判定した回数）
- n : 各SOAでの試行数
- $\hat{p}$: フィッティングモデルによる予測確率
- Pearsonカイ二乗統計量（二項分布モデルに基づく）

解釈:

- **1に近い値**: モデルがデータを適切に説明している（理想的な値）
- **1より大きい値**: モデルの説明力が不十分、または過分散が存在
- **1より小さい値**: モデルが過剰に適合している可能性、またはデータの分散が小さい

注意点:

- cold/warm条件では、比率データを直接扱うため、試行数の情報が考慮されていない
- spatial_cold条件では、二項分布モデルに基づくため、試行数の情報が適切に考慮されている
- 両者の値は直接比較できない（計算方法が異なるため）

使用箇所:

- `Gaussian_fitting_integrate_cold.py`（単純な残差平方和ベース）
- `Gaussian_fitting_integrate_warm.py`（単純な残差平方和ベース）
- `Gaussian_fitting_integrate_spatial_cold.py`（Pearsonカイ二乗統計量ベース）

2. 詳細指標（spatial_cold条件のみ）

`Gaussian_fitting_integrate_spatial_cold.py`では、二項分布モデルに基づくより詳細な適合度指標を計算しています。これらの指標は、成功数（k）と試行数（n）の情報を使用して、確率データのフィッティングをより正確に評価します。

2.1 Reduced Deviance（正規化デビアンس）

定義:

$$\text{Reduced Deviance} = \text{Deviance} / (n - p)$$

計算式:

$$\text{Deviance} = -2 \times (\text{LL_model} - \text{LL_saturated})$$

- `LL_model`: フィッティングモデルの対数尤度
- `LL_saturated`: 飽和モデル（各データ点で観測確率を完全に説明するモデル）の対数尤度

解釈:

- Reduced χ^2 と同様に、**1に近い値が理想的**
- 二項分布モデルでは、Reduced Devianceの方がReduced χ^2 よりも安定した指標とされる
- 特に試行数が少ない場合や、確率が0や1に近い場合に有効

使用箇所:

- `Gaussian_fitting_integrate_spatial_cold.py`

2.2 AIC（Akaike Information Criterion）

定義:

$$\text{AIC} = 2k - 2\ln(L)$$

- **k**: パラメータ数
- **L**: 尤度（対数尤度の指数）

計算式:

$$\text{AIC} = 2 \times \text{p_param} - 2 \times \text{loglik}$$

- **p_param**: パラメータ数（4: A, μ , σ , B）
- **loglik**: フィッティングモデルの対数尤度（**LL_model**）

解釈:

- **小さいほど良い**（モデルの複雑さと適合度のバランスを考慮）
- モデル比較に使用（異なるモデル間で比較可能）
- パラメータ数のペナルティを含むため、過剰適合を抑制

使用箇所:

- **Gaussian_fitting_integrate_spatial_cold.py**

2.3 BIC (Bayesian Information Criterion)

定義:

$$\text{BIC} = k \cdot \ln(n) - 2\ln(L)$$

- **k**: パラメータ数
- **n**: データ点数
- **L**: 尤度

計算式:

$$\text{BIC} = \text{p_param} \times \ln(N) - 2 \times \text{loglik}$$

- **p_param**: パラメータ数（4: A, μ , σ , B）
- **N**: 有効なデータ点数（NaN値や試行数0のデータポイントを除外した後の数）
- **loglik**: フィッティングモデルの対数尤度（**LL_model**）

解釈:

- **小さいほど良い**（AICと同様）
- AICよりもパラメータ数に対するペナルティが大きい（データ点数に依存）
- サンプルサイズが大きい場合、より単純なモデルを 선호する傾向

使用箇所:

- `Gaussian_fitting_integrate_spatial_cold.py`
-

2.4 McFadden's Pseudo R²

定義:

$$R^2_{\text{mcf}} = 1 - (LL_{\text{model}} / LL_{\text{null}})$$

- `LL_model`: フィッティングモデルの対数尤度
- `LL_null`: ヌルモデル（定数確率モデル）の対数尤度

計算式:

$$\begin{aligned} p_0 &= \sum k / \sum n \quad (\text{全データの平均成功率、有効なデータポイントのみを使用}) \\ LL_{\text{model}} &= \sum [k \cdot \ln(\hat{p}) + (n-k) \cdot \ln(1-\hat{p})] \quad (\text{フィッティングモデルの対数尤度}) \\ LL_{\text{null}} &= \sum [k \cdot \ln(p_0) + (n-k) \cdot \ln(1-p_0)] \quad (\text{ヌルモデルの対数尤度}) \\ R^2_{\text{mcf}} &= 1 - (LL_{\text{model}} / LL_{\text{null}}) \end{aligned}$$

- 注: 実際の実装では、`scipy.special.xlogy`関数を使用して数値的に安定した計算を行っている

解釈:

- **0-1の範囲で、1に近いほど良い適合**
- 通常のR²（決定係数）の一般化版
- 確率モデルや一般化線形モデルで使用される

使用箇所:

- `Gaussian_fitting_integrate_spatial_cold.py`
-

2.5 Deviance-based R²（デビアンスペースのR²）

定義:

$$R^2_{\text{dev}} = 1 - (Dev_{\text{model}} / Dev_{\text{null}})$$

- `Dev_model`: フィッティングモデルのデビアン
- `Dev_null`: ヌルモデルのデビアン

計算式:

```
LL_saturated = Σ[k・ln(k/n) + (n-k)・ln(1-k/n)]    (飽和モデルの対数尤度)
Dev_model = -2 × (LL_model - LL_saturated)          (モデルのデビアンس)
Dev_null = -2 × (LL_null - LL_saturated)            (ヌルモデルのデビアンス)
R²_dev = 1 - (Dev_model / Dev_null)
```

- 注: 実際の実装では、確率が0や1に近い場合にクリッピング (1e-12から1-1e-12の範囲) を適用している

解釈:

- **0-1の範囲で、1に近いほど良い適合**
- デビアンス (モデルと飽和モデルの差) に基づく R²
- McFadden's R²と類似だが、飽和モデルを基準としている

使用箇所:

- `Gaussian_fitting_integrate_spatial_cold.py`

2.6 RMSE (Root Mean Squared Error)**定義:**

```
RMSE = √[Σ(obs_prop - p̂)² / n]
```

- `obs_prop`: 観測された成功率 (k/n)
- `p̂`: フィッティングモデルによる予測確率
- `n`: データ点数

解釈:

- **小さいほど良い** (予測誤差が小さい)
- 残差の二乗平均の平方根
- 単位は確率 (0-1の範囲)

使用箇所:

- `Gaussian_fitting_integrate_spatial_cold.py`

2.7 MAE (Mean Absolute Error)**定義:**

```
MAE = Σ|obs_prop - p̂| / n
```

- **obs_prop**: 観測された成功率 (k/n)
- **p̂**: フィッティングモデルによる予測確率
- **n**: データ点数

解釈:

- **小さいほど良い** (予測誤差が小さい)
- 残差の絶対値の平均
- 外れ値の影響がRMSEよりも小さい

使用箇所:

- **Gaussian_fitting_integrate_spatial_cold.py**

2.8 Weighted R² (重み付き決定係数)

定義:

$$R^2_{\text{weighted}} = 1 - (\text{SS}_{\text{res_weighted}} / \text{SS}_{\text{tot_weighted}})$$

計算式:

$$\begin{aligned} \text{mean_w} &= \Sigma(w \times y_{\text{obs}}) / \Sigma w && \text{(重み付き平均)} \\ \text{SS}_{\text{res}} &= \Sigma[w \times (y_{\text{obs}} - y_{\text{pred}})^2] && \text{(重み付き残差平方和)} \\ \text{SS}_{\text{tot}} &= \Sigma[w \times (y_{\text{obs}} - \text{mean_w})^2] && \text{(重み付き総平方和)} \\ R^2_{\text{weighted}} &= 1 - (\text{SS}_{\text{res}} / \text{SS}_{\text{tot}}) \end{aligned}$$

- **w**: 各データ点の重み (試行数nなどを想定)
- **y_obs**: 観測値 (成功率)
- **y_pred**: 予測値 (フィッティング値)

解釈:

- **0-1の範囲で、1に近いほど良い適合**
- 試行数が多いデータ点により大きな重みを与える
- 試行数が不明な場合は通常のR²を使用

使用箇所:

- **Gaussian_fitting_integrate_spatial_cold.py** (比率データの場合)

指標の使い分け

条件別の使用状況

指標	cold	warm	spatial_cold	備考
----	------	------	--------------	----

指標	cold	warm	spatial_cold	備考
Reduced χ^2	✓	✓	✓	計算方法が異なる（cold/warm: 残差平方和、spatial_cold: Pearsonカイ二乗）
Reduced Deviance	-	-	✓	二項分布モデルに基づく（推奨指標）
AIC	-	-	✓	モデル比較用
BIC	-	-	✓	モデル比較用（AICより単純なモデルを 선호）
McFadden's R^2	-	-	✓	説明力の評価
Deviance R^2	-	-	✓	説明力の評価（推奨）
RMSE	-	-	✓	予測精度の評価
MAE	-	-	✓	予測精度の評価（推奨）
Weighted R^2	-	-	△	試行数が不明な場合のみ使用

凡例:

- ✓: 使用される
- -: 使用されない
- △: 条件付きで使用される

推奨される評価方法

cold/warm条件での評価

1. 基本的な適合度評価:
- Reduced χ^2 （1に近い確認）
 - 注意: 試行数の情報が考慮されていないため、解釈には注意が必要

spatial_cold条件での評価

1. 基本的な適合度評価:
- **Reduced Deviance**（推奨）：二項分布モデルでは最も安定した指標
 - Reduced χ^2 : Reduced Devianceと併用して確認
 - 両者が1に近い値であれば、モデルが適切にデータを説明している
2. モデル比較:
- **AIC**: データ点数が少ない場合に推奨
 - **BIC**: データ点数が多い場合に推奨（より単純なモデルを 선호）
 - 異なるモデル間で比較する際に使用
3. 説明力の評価:
- **Deviance R^2** （推奨）：飽和モデルを基準とした説明力

- McFadden's R^2 : ヌルモデルを基準とした説明力
- 両者が0.2-0.4程度でも良好な適合とされることがある

4. 予測精度の評価:

- **MAE**: 外れ値の影響が小さい (推奨)
- **RMSE**: 外れ値の影響を受けやすい
- 両者を併用して評価

注意点

- **cold/warm条件とspatial_cold条件の違い:**

- cold/warm条件では、比率データを直接扱うため、試行数の情報が考慮されていない
- spatial_cold条件では、二項分布モデルに基づくため、試行数の情報が適切に考慮されている
- 両条件間でReduced χ^2 の値を直接比較することはできない (計算方法が異なるため)

- **Reduced χ^2 と Reduced Deviance の違い:**

- 通常、両者は近い値を取るが、試行数が少ない場合や確率が極端な場合に差が生じることがある
- 二項分布モデルでは、Reduced Devianceの方がより安定した指標とされる
- コードでは、両者の相対的な差が20%を超える場合に警告メッセージが表示される

- **AIC と BIC の違い:**

- BICはサンプルサイズが大きい場合、より単純なモデルを選好する傾向がある
- データ点数が多い場合はBIC、少ない場合はAICを重視することが推奨される
- モデル選択時は、両者を併用して評価することが推奨される

- **R^2 指標の解釈:**

- 通常の線形回帰の R^2 とは異なり、擬似 R^2 は0.2-0.4程度でも良好な適合とされることがある
- 確率モデルでは、完全な説明 ($R^2=1$) は通常達成不可能
- Deviance R^2 とMcFadden's R^2 は異なる基準 (飽和モデル vs ヌルモデル) を使用しているため、値が異なることがある

- **指標の選択:**

- 可能な限り、spatial_cold条件のように二項分布モデルに基づく指標を使用することが推奨される
- 試行数の情報が利用可能な場合は、必ずその情報を使用した指標を計算する

実装の詳細

計算の流れ

cold/warm条件

1. データの準備:

- 各SOAでの成功率 (比率データ) を計算
- 試行数の情報は使用しない

2. フィッティング:

- ガウシアン関数でフィッティングを実行
- パラメータ (A, μ , σ , B) を推定

3. 指標の計算:

- Reduced χ^2 を計算 (単純な残差平方和ベース)

4. 結果の保存:

- 各指標をCSVファイルに保存

spatial_cold条件

1. データの準備:

- 各SOAでの成功数 (k) と試行数 (n) を計算
- 成功率 (k/n) を計算

2. フィッティング:

- ガウシアン関数でフィッティングを実行 (再パラメータ化された関数を使用)
- パラメータ (A, μ , σ , B) を推定

3. 指標の計算:

- 二項分布モデルに基づく指標を計算 (`metrics_binomial`関数)
 - Reduced χ^2 (Pearsonカイ二乗統計量ベース)
 - Reduced Deviance
 - AIC, BIC
 - McFadden's R^2 , Deviance R^2
 - RMSE, MAE
- または、比率データの場合は重み付き R^2 を計算 (`weighted_R2`関数)

4. 結果の保存:

- 各指標をCSVファイルに保存

コード内の関数

Gaussian_fitting_integrate_cold.py / Gaussian_fitting_integrate_warm.py

- `fit_gaussian()`: ガウシアン関数でフィッティングし、Reduced χ^2 を計算 (単純な残差平方和ベース)

Gaussian_fitting_integrate_spatial_cold.py

- `fitfunc()`: 再パラメータ化されたガウシアン関数 (確率が0-1の範囲に収まることを保証)
- `metrics_binomial()`: 二項モデルに基づく適合度指標を計算
 - 対数尤度、AIC、BIC
 - Pearsonカイ二乗統計量、Reduced χ^2
 - Reduced Deviance

- McFadden's R^2 、Deviance R^2
 - RMSE、MAE
 - `weighted_R2()`: 重み付き決定係数を計算（試行数が不明な場合に使用）
 - `fit_gaussian()`: ガウシアン関数でフィッティングし、各種指標を計算
-

まとめ

主要なポイント

1. 条件による計算方法の違い:

- **cold/warm条件**: 比率データを直接扱い、単純な残差平方和ベースのReduced χ^2 を計算
- **spatial_cold条件**: 二項分布モデルに基づき、試行数の情報を適切に考慮した詳細な指標を計算

2. 推奨される評価方法:

- **spatial_cold条件**: Reduced Devianceを主要指標として使用し、AIC/BICでモデル比較、Deviance R^2 で説明力を評価
- **cold/warm条件**: Reduced χ^2 を使用するが、試行数の情報が考慮されていないことに注意

3. 指標の選択指針:

- 可能な限り、試行数の情報を使用した二項分布モデルに基づく指標を使用
- 複数の指標を併用して、多角的に評価することが重要
- モデル比較時は、AICとBICの両方を確認

4. 注意すべき点:

- cold/warm条件とspatial_cold条件のReduced χ^2 は計算方法が異なるため、直接比較できない
- 擬似 R^2 は通常の線形回帰の R^2 とは異なり、0.2-0.4程度でも良好な適合とされることがある
- Reduced DevianceとReduced χ^2 の値が大きく異なる場合（相対差20%以上）は、データやモデルに問題がある可能性がある

今後の改善点

- cold/warm条件でも、試行数の情報が利用可能であれば、二項分布モデルに基づく指標を計算することを検討
 - 各指標の閾値や解釈の基準を、実際のデータに基づいて明確化
-

実際のデータに基づく適合度の考察

分析結果の概要

spatial_cold条件における14名の被験者データと集約データの適合度指標を分析した結果、以下の知見が得られました。

被験者別の詳細データ

被験者	PSS (ms)	Window_size (ms)	Prob	AIC	BIC	Reduced_deviance	Reduced_chi2
1	-303.0	399.0	0.72	286.21	287.80	15.182	5233.680
2	-162.0	864.0	1.00	172.05	173.64	4.989	14.059
3	-840.0	183.0	0.70	237.18	238.77	2.152	1.573
4	-229.0	796.0	0.88	196.32	197.91	0.755	0.810
5	-371.0	350.0	0.76	184.16	185.75	7.160	10256.876
6	-447.0	320.0	0.75	239.38	240.97	0.491	0.513
7	-278.0	812.0	0.88	196.76	198.35	2.716	6.268
8	-708.0	567.0	0.63	243.69	245.29	0.935	0.837
9	-280.0	593.0	0.88	137.49	139.08	0.243	0.126
10	-355.0	775.0	0.83	217.12	218.71	0.936	0.798
11	-578.0	319.0	0.54	262.39	263.99	0.795	0.760
12	-745.0	829.0	0.90	208.38	209.97	1.262	1.263
13	-694.0	680.0	0.75	247.88	249.47	1.809	1.634
14	-624.0	1301.0	0.95	219.85	221.44	1.598	1.477
集約	-423.0	617.0	0.65	3354.63	3356.22	3.467	3.148

凡例:

- **PSS**: Point of Subjective Simultaneity（主観的同時点、ms単位）
- **Window_size**: 50% 閾値の窓幅（ms単位）
- **Prob**: ピーク時の確率（0-1の範囲）
- **AIC**: Akaike Information Criterion（小さいほど良い）
- **BIC**: Bayesian Information Criterion（小さいほど良い）
- **Reduced_deviance**: 正規化されたデビアンس（1に近いほど良い）
- **Reduced_chi2**: 正規化されたPearsonカイ二乗統計量（1に近いほど良い）

主要な発見

1. Reduced DevianceとReduced Pearson χ^2 の比較

被験者別の結果:

- **Reduced Deviance**: 0.243～15.182（範囲が広い）
- **Reduced Pearson χ^2** : 0.126～10256.876（極端に大きな値が存在）

集約データ:

- Reduced Deviance: 3.467
- Reduced Pearson χ^2 : 3.148
- 両指標が比較的近い値（相対差約9%）を示しており、集約データでは安定した評価が可能

2. 指標間の不一致

極端な不一致を示す被験者:

- **被験者1**: Reduced Deviance=15.182, Reduced χ^2 =5233.680（相対差99.7%）
- **被験者5**: Reduced Deviance=7.160, Reduced χ^2 =10256.876（相対差99.9%）

注意: 全ての被験者は11のSOAに対してそれぞれ20回の繰り返しを行っているため、試行数は一定（各SOAで20回）です。したがって、これらの被験者での不一致は、試行数の問題ではなく、**確率が極端な値（0や1に近い）のデータポイントが存在する**ことが原因である可能性が高い。特に、観測された成功率が0%や100%に近い場合、Pearsonカイ二乗統計量の分母（ $n \cdot p \cdot (1-p)$ ）が非常に小さくなり、数値的に不安定になる傾向があります。

良好な一致を示す被験者:

- **被験者6**: Reduced Deviance=0.491, Reduced χ^2 =0.513（相対差4.3%）
- **被験者10**: Reduced Deviance=0.936, Reduced χ^2 =0.798（相対差14.7%）
- **被験者12**: Reduced Deviance=1.262, Reduced χ^2 =1.263（相対差0.1%）

これらの被験者では、両指標が近い値を示しており、データが安定していることが示唆される。

3. 良好な適合度を示す被験者

Reduced Deviance < 1.0の被験者（理想的に近い適合度）:

- 被験者6: 0.491
- 被験者9: 0.243（最も良好）
- 被験者10: 0.936
- 被験者11: 0.795
- 被験者4: 0.755

これらの被験者では、ガウシアン関数によるフィッティングがデータを適切に説明している。

4. 改善が必要な被験者

Reduced Deviance > 5.0の被験者（適合度が低い）:

- 被験者1: 15.182
- 被験者5: 7.160
- 被験者2: 4.989

これらの被験者では、モデルの説明力が不十分である可能性がある。考えられる原因:

- データのばらつきが大きい
- ガウシアン関数が被験者の反応パターンを適切に捉えていない
- 試行数が少ない、またはデータの質に問題がある

推奨される評価方法（実データに基づく）

1. 主要指標としてReduced Devianceを使用

- Pearsonカイ二乗統計量は試行数が少ない場合や確率が極端な場合に不安定
- Reduced Devianceの方がより安定した指標として機能

2. 適合度の評価基準（Reduced Devianceに基づく）：

- **良好（< 1.0）**：モデルがデータを適切に説明している
- **許容範囲（1.0～3.0）**：実用的な範囲内だが、改善の余地がある
- **要改善（> 3.0）**：モデルの説明力が不十分、データの再検討が必要

3. 指標間の不一致の解釈:

- Reduced DevianceとReduced χ^2 の相対差が20%を超える場合、確率が極端な値（0や1に近い）のデータポイントが存在する可能性を検討
- 試行数は一定（各SOAで20回）であるため、不一致の原因は試行数ではなく、データの分布特性（極端な確率値）にある
- 集約データでは両指標が近い値を示す傾向があるため、個別被験者のデータよりも集約データでの評価が安定

集約データの特徴

集約データでは：

- Reduced Deviance: 3.467
- Reduced Pearson χ^2 : 3.148
- 両指標が比較的近い値（相対差約9%）

これは、個別被験者のデータを集約することで、**各SOAでの総試行数が増加**（20回×被験者数）し、統計的な安定性が向上したことを示している。特に、個別被験者で極端な確率値（0%や100%）が観測されても、集約することで平均化され、Pearsonカイ二乗統計量の分母が安定するため、両指標が近い値を示すようになります。集約データでの評価は、個別被験者の評価よりも信頼性が高い。

結論

1. Reduced Devianceを主要指標として使用することが推奨される

- Pearsonカイ二乗統計量は確率が極端な値（0や1に近い）の場合に不安定
- 試行数は一定（各SOAで20回）であるが、観測された成功率が0%や100%に近い場合、Pearsonカイ二乗統計量の分母が小さくなり、数値的に不安定になる
- Reduced Devianceの方がより安定した評価を提供

2. 被験者間の適合度には大きなばらつきがある

- 良好な適合度（Reduced Deviance < 1.0）を示す被験者もいれば、改善が必要（> 5.0）な被験者も存在
- 試行数は一定であるが、被験者ごとの反応パターン（確率分布）が異なるため、適合度にばらつきが生じる
- 個別被験者のデータ特性を考慮した評価が必要

3. 集約データでの評価がより安定している

- 各SOAでの総試行数が増加（20回×被験者数）することにより、統計的な安定性が向上
 - 個別被験者で極端な確率値が観測されても、集約することで平均化され、両指標が近い値を示す
 - 集約データでの評価は、個別被験者の評価よりも信頼性が高い
-

参考文献

- Akaike, H. (1974). A new look at the statistical model identification. *IEEE Transactions on Automatic Control*, 19(6), 716-723.
 - Schwarz, G. (1978). Estimating the dimension of a model. *Annals of Statistics*, 6(2), 461-464.
 - McFadden, D. (1974). Conditional logit analysis of qualitative choice behavior. In *Frontiers in Econometrics* (pp. 105-142).
 - Burnham, K. P., & Anderson, D. R. (2002). *Model Selection and Multimodel Inference: A Practical Information-Theoretic Approach* (2nd ed.). Springer.
-

更新履歴

- 2026-01-27: 初版作成
- 2026-01-27: 指標の整理と詳細化（cold/warm条件とspatial_cold条件の違いを明確化、計算式の詳細化、推奨評価方法の追加）
- 2026-01-27: 実際のデータに基づく適合度の考察を追加（14名の被験者データと集約データの分析結果）